

Pronóstico de Consumo de Energía Eléctrica utilizando Redes Neuronales Artificiales

Daniela Elizabeth Cruz Morete and Aana Beatriz Bestard Columbie and Lianet Soler Jay

Universidad de Oriente

RESUMEN: Este trabajo presenta el desarrollo de un modelo de red neuronal para predecir el consumo eléctrico de la empresa DESOFT, una compañía de servicios de software. La motivación es la necesidad de DESOFT de contar con pronósticos precisos a corto y mediano plazo del consumo energético, con el fin de optimizar la planificación, mejorar la eficiencia y reducir los costos. Se utilizó un conjunto de datos históricos del consumo eléctrico de DESOFT desde enero de 2015 hasta diciembre de 2023. Se entrenó una red neuronal de regresión para aprender patrones y relaciones no lineales en los datos. El entrenamiento y evaluación del modelo se llevaron a cabo en Google Colab, aplicando técnicas de normalización y división de datos. Los resultados muestran que el modelo de red neuronal desarrollado logró un error absoluto medio (MAE) de 0.05 Energy en el conjunto de prueba. Este desempeño indica que el modelo puede generar predicciones precisas, lo que permitirá a DESOFT mejorar la planificación energética, optimizar el uso de recursos y reducir los costos operativos.

Palabras Clave: Redes Neuronales, consumo energético, predicción.

Introducción

Las redes neuronales han demostrado ser herramientas muy potentes y versátiles para predecir el consumo de energía. Estas técnicas de aprendizaje automático pueden manejar grandes cantidades de datos históricos, descubrir patrones complejos y no lineales y adaptarse a cambios en los perfiles de consumo. Esto los convierte en una opción extremadamente eficaz para la previsión tanto a corto como a largo plazo.

En el sector empresarial, la capacidad de predecir con precisión el consumo de energía es increíblemente valiosa. Permite a las empresas optimizar su planificación energética, mejorar la eficiencia operativa, reducir costos y cumplir con las regulaciones ambientales. Al anticipar los patrones de consumo, las empresas pueden tomar decisiones bien informadas sobre la adquisición de energía, medidas de eficiencia y gestión de la demanda.

En el presente documento, se ilustra el procedimiento de entrenamiento de una red neuronal de regresión para predecir el consumo energético de la empresa de aplicaciones informáticas Desoft. Se elige el uso de redes neuronales por ser uno de los métodos que más se ajustan para la predicción del consumo de energía y por ser altamente efectivas en tareas de predicción. Para el entrenamiento y uso de la red neuronal, se hará uso de la herramienta Google Colab, la cual proporciona recursos potentes de forma gratuita. De esta manera, será posible acceder al entorno de desarrollo desde cualquier dispositivo, independientemente de sus características. Se utilizará el lenguaje de programación Python, junto con librerías especializadas en aprendizaje automático, como TensorFlow y Keras. Para el entrenamiento de la red neuronal se utilizó un conjunto de datos históricos del consumo energético de la empresa desde enero de 2015 hasta diciembre de 2023. Se creó, simuló y validó una red neuronal para el pronóstico del consumo de energía eléctrica, obteniendo un error de aproximación de 5%, debido a la existencia de pocos datos en el entrenamiento. Con este valor obtenido, se pudieron determinar las potencialidades técnicas de ahorro, así como los beneficios económicos. En este documento, se seguirá una estructura similar, adaptando la metodología a la predicción del consumo energético de la empresa Desoft. Se presentarán fragmentos de código relevantes, mientras que el código completo se encontrará disponible en GitHub, junto con comentarios y cabeceras de texto que faciliten la comprensión del cuaderno de trabajo.

Problemática

DESOFT, empresa especializada en servicios de software, se enfrenta a la necesidad de mejorar la planificación y gestión de su consumo eléctrico. Aunque la empresa dispone de datos históricos sobre el uso de energía, carece de un modelo predictivo que le permita anticiparse y prepararse para futuras fluctuaciones de la demanda. Las predicciones precisas del consumo de electricidad a corto y medio plazo serían muy beneficiosas para DESOFT, ya que le permitirían:

Optimizar la planificación energética: pronósticos confiables del consumo de electricidad ayudarían a DESOFT a planificar mejor sus recursos, presupuestos y estrategias de adquisición de energía.

Mejorar la eficiencia operativa: al anticipar picos y fluctuaciones en el consumo, la empresa podría implementar medidas de eficiencia energética y ajustar el uso de recursos de manera oportuna.

Reducir los costos operativos: Las predicciones precisas del consumo de electricidad permitirían a DESOFT negociar mejor los contratos de suministro, evitar sanciones por consumo excesivo y optimizar la facturación de energía.

Para afrontar este reto, DESOFT ha decidido desarrollar un modelo predictivo basado en una red neuronal que pueda aprender de datos históricos de consumo eléctrico y generar previsiones fiables a corto y medio plazo. El objetivo es que este modelo de red neuronal permita a DESOFT anticipar y planificar mejor su consumo de electricidad, lo que se traducirá en una mayor eficiencia operativa, reducción de costos y un mejor rendimiento general de la empresa.

Métodos más usados para el pronóstico de consumo de energía eléctrica

La predicción del consumo de energía tiene vital importancia para la sociedad en general. Los

métodos más usados en el pronóstico de consumo de energía son:

- Método de la tendencia histórica simple

El método de la tendencia histórica para el cálculo del consumo futuro de energía eléctrica se

utilizó hasta finales de los años 70. En muchos países se consideraba un aumento de 7,5 % anual

del consumo y su duplicación por cada década. Inicialmente este método se aplicó al análisis de

las finanzas [1].

Este método solo es conveniente usarlo para predicciones a largo plazo que no requieran de gran

exactitud; para análisis a corto y mediano plazo es inexacto, por lo que no es aconsejable su uso.

- Método de usuarios finales

El método de usuarios finales se basa en las ecuaciones clásicas que expresan el consumo de

energía eléctrica para cualquier local, área administrativa, centro de trabajo, etc., donde existan

consumidores eléctricos, en dependencia de su número, potencia y tiempo de utilización [2].

Este método se basa en ecuaciones definidas clásicas de la ingeniería eléctrica. Es fácilmente

realizable en hojas de cálculo. El mismo presenta desventaja pues requiere de una contabilidad

muy exacta del tipo de equipamiento, de su número y de la fecha de puesta en funcionamiento

además, el tiempo de uso promedio del equipamiento que influye significativamente en el consumo

y su determinación presenta muchas inexactitudes. También es necesario conocer con

anticipación la fecha de adquisición y montaje del nuevo equipamiento. Por lo antes expuesto no

es aconsejable su uso.

- Métodos paramétricos

Los métodos paramétricos se ocupan de obtener, a partir del análisis estadístico y matemático de

los valores reales de las variables, los valores que tendrían los parámetros de los modelos en los

que esas variables actúan, así como de comprobar el grado de validez de esos modelos, y ver en

qué medida estos modelos pueden usarse para la predicción del cambio futuro de las variables

definidas como independientes [3]. Este método no es aconsejable para su utilización en esta

investigación pues su exactitud aumenta con el número de datos, lo que no siempre es posible

obtener en la cantidad requerida además necesita de elevada correlación entre las variables

independientes y la dependiente, exige baja autocorrelación entre las variables independientes.

- Métodos con aplicación de la inteligencia artificial

Las Redes Neuronales Artificiales (RNA) constituyen un potente instrumento para la aproximación

de funciones no lineales. Su uso resulta especialmente útil en la modelización de aquellos

fenómenos complejos donde la presencia de relaciones no lineales entre las variables es habitual

[4]. Una de las aplicaciones de las RNA es la predicción de consumo de energía eléctrica. Por lo

anterior expuesto es aconsejable la utilización en esta investigación.

Características de los datos

Para entrenar la red neuronal de regresión, fue necesario contar con un conjunto de datos históricos que incluyó variables de año, mes y consumo eléctrico.

Los datos de consumo energético cargados desde un archivo “csv” fueron plotados para analizar si se aprecia estacionalidad y detectar datos erróneos, de forma tal que la red neuronal pueda aprender de las relaciones entre la variable de entrada y de salida.




Figura 1. Relación de Evolución del consumo de energético de Desoft con respecto al año.




Figura 2. Relación de Evolución del consumo de energético de Desoft con respecto al mes.

Teniendo como valores extremos:

	Año	Mes	Energia
min	2015.0	1.0	3878.0
max	2023.0	12.0	170778.0

Detalles de implementación

Para implementar de manera eficiente red neuronal para predecir el consumo energético se emplearon diversas librerías de Python ampliamente utilizadas en el campo del aprendizaje automático.

Librerías Utilizadas

1. Pandas (pd):

- Gestión y manipulación de datos estructurados contenidos en el archivo CSV "desoft.csv".

2. NumPy:

- Representación numérica de los datos de entrada y salida.

3. Matplotlib.pyplot (plt):

- Visualización de los datos y resultados obtenidos.

4. **Scikit-learn (sklearn)**:

- Funciones de preprocesamiento y división de datos.
- Clase `MinMaxScaler` del módulo `preprocessing`:
- Normalización de los datos de entrada y salida en un rango común.

5. TensorFlow (tf):

- Definición y entrenamiento de la red neuronal.

6. Keras:

- Definición concisa de la arquitectura de la red neuronal.
- Compilación del modelo con los hiperparámetros adecuados.
- Entrenamiento del modelo utilizando los datos de entrenamiento.
- Evaluación del desempeño del modelo en el conjunto de prueba.

Luego de analizados y cargados los datos del csv, se normalizaron los datos, En este caso, se utilizó la función MinMaxScaler de la librería Scikit-learn para normalizar tanto los datos de entrada como las etiquetas, asegurando que estén dentro del mismo rango, como se muestra en la figura 3.

```
# Normalización de los datos
scaler_X = MinMaxScaler()
scaler_y = MinMaxScaler()

X_scaled = scaler_X.fit_transform(dataset[['Año', 'Mes']])
y_scaled = scaler_y.fit_transform(dataset[['Energia']].values.reshape(-1, 1))
```

Figura 3. Normalización de los datos

Posteriormente la separación del dataset en los conjuntos de entrenamiento y prueba, con un 20% de los datos se destinados a prueba, mientras que el resto se utiliza para entrenar el modelo.

Construcción del modelo

El modelo se construyó con una estructura secuencial con tres capas densamente conectadas. Con dos capas ocultas, lo cual es una arquitectura común y efectiva para problemas de regresión. Tener múltiples capas ocultas permite a la red

aprender representaciones más complejas de los datos de entrada, capturando relaciones no lineales que serían difíciles de modelar con una sola capa oculta. Cada una de las dos capas ocultas tiene 64 neuronas y una capa de salida de una única unidad.

La función de activación utilizada en las capas ocultas es ReLU (Unidad Lineal Rectificada), una función de activación no lineal ampliamente utilizada en redes neuronales. ReLU introduce no linealidad en el modelo sin aumentar significativamente la complejidad computacional. Además, ReLU generalmente ofrece un proceso de entrenamiento más estable y rápido en comparación con otras funciones de activación.

Se define la función de pérdidas como el error cuadrático medio y se escoge el método de optimización RMSprop, que ajusta la tasa de aprendizaje individual para cada parámetro, basándose en el promedio de los gradientes recientes. Ver Figura 4

```
# Definir y compilar el modelo
def build_model():
    model = keras.Sequential([
        layers.Dense(64, activation='relu', input_shape=train_dataset.shape[1:]),
        layers.Dense(64, activation='relu'),
        layers.Dense(1)
    ])

    optimizer = tf.keras.optimizers.RMSprop(0.001)

    model.compile(loss='mse',
                  optimizer=optimizer,
                  metrics=['mae', 'mse'])

    return model

model = build_model()
model.summary()
```

Figura 4. Definición de la red neuronal

Entrenamiento de la red y resultados

Para el entrenamiento de la red, se hace uso de la función `model.fit()`, donde se le pasan los valores de entrada y sus salidas teóricas. Se le indica el número de épocas de entrenamiento (1000) lo cual es una cantidad razonable para comenzar y que el modelo se entrene adecuadamente.

Posterior a ello, Se miden las métricas del entrenamiento:

	loss	mae	mse	val_loss	val_mae	val_mse	epoch
995	0.000107	0.007443	0.000107	0.000441	0.016533	0.000441	995
996	0.000172	0.010166	0.000172	0.000269	0.012788	0.000269	996
997	0.000109	0.007646	0.000109	0.000286	0.012884	0.000286	997
998	0.000109	0.007674	0.000109	0.000326	0.013958	0.000326	998
999	0.000118	0.008184	0.000118	0.000283	0.012916	0.000283	999

Figura 5. Métricas al fin del entrenamiento

Los valores de pérdida (Loss), error absoluto medio (MAE) y error cuadrático medio (MSE) son muy bajos, tanto para el conjunto de entrenamiento como para el de validación, arrojando resultados prometedores.

Posteriormente, se hace uso de la función `model.evaluate()`. Donde se le aporta entrada y salida teóricas. Se obtiene un *loss* de 0.0392. en el conjunto de prueba sugiere que, en promedio, las predicciones del modelo se desvían un 5% en unidades de energía de los valores reales.

```
# Evaluar el modelo
loss, mae, mse = model.evaluate(test_dataset, test_labels, verbose=2)
print("Testing set Mean Abs Error: {:.5,2f} Energy".format(mae))
```

```
1/1 - 0s - loss: 0.0392 - mae: 0.0508 - mse: 0.0392 - 34ms/epoch - 34ms/step
Testing set Mean Abs Error: 0.05 Energy
```

Figura 6. Comportamiento sobre el dataset de validación




Figura 7. Predicciones frente a valores reales de consumo energético.

Luego se realizan algunas predicciones.

```
1/1 [=====] - 0s 22ms/step
Año: 2020, Mes: 12
Valor real: 5336.00
Predicción: 5608.95
Diferencia: 272.95
-----
1/1 [=====] - 0s 23ms/step
Año: 2017, Mes: 8
Valor real: 16472.00
Predicción: 15669.22
Diferencia: 802.78
-----
```

Como se puede apreciar, la red no es tan precisa como cabría esperar. Los datos son demasiado escasos, por lo que elaborar una predicción sobre los mismos no tiene por qué ser adecuada.

Como alternativa a este tipo de red, las redes LSTM [son también secuenciales], son ampliamente utilizadas para aprender secuencias. Este enfoque podría dar un mejor resultado que el obtenido puesto que se aprecia cierta estacionalidad en los datos de consumo energético de la figura 1.

Conclusiones

El estudio actual ha evidenciado la capacidad y potencial de las redes neuronales en la predicción del consumo de energía en el ámbito empresarial, especialmente para la compañía Desoft dedicada a aplicaciones informáticas. A pesar de ciertas limitaciones identificadas, los resultados obtenidos brindan perspectivas valiosas y abren puertas a mejoras y aplicaciones futuras.

Se ha comprobado que las redes neuronales pueden predecir con éxito el consumo de energía en Desoft, con solo un 5% de margen de error. A pesar de las limitaciones debidas a la falta de datos, este modelo representa un punto de partida prometedor. Se ha identificado un potencial significativo para mejorar tanto la eficiencia energética como la toma de decisiones dentro de la empresa. Las próximas etapas incluyen explorar redes más avanzadas y recopilar datos más detallados. En general, este trabajo sienta las bases para mejoras en la predicción del consumo energético en Desoft, lo que podría resultar en una reducción de costos y una mayor sostenibilidad. Además, resalta la posibilidad de implementar soluciones avanzadas de aprendizaje automático incluso con recursos limitados, lo cual podría ser beneficioso para otras compañías en situaciones similares.

References

[1]D. V. Real, "Modelos para la predicción de la demanda de energía eléctrica," Tesis de

Maestria, Universidad Autónoma de Andalucía., 2009.

http://www.fondosdigitales.us.es/public_thesis/388/9081.pdf

[2] G. F. Filho and R. A. Dias, "Estimativa de demanda em edifícios residenciais: uma análise

comparada," Revista Eletricidade Moderna, vol. X, n. 2, pp. 16 - 22, 2010. ISSN 1699-

6569, Disponible:

<http://www.labplan.ufsc.br/congressos/Induscon%202010/fscommand/web/docs/T0821.pdf>

[3] D. Yu and S. Tao, "The Method of Classification for Financial Distress Prediction Indexes

of Sinopec Corp. and Its Subsidiaries Based on Self-Organizing Map Neural Network.," in

Fourth International Conference on Computational and Information Sciences (ICCIS). ,

Chongqing. China., 2012, pp. 590 - 593., ISBN: 978-1-4673-2406-9.,

<http://ieeexplore.ieee.org/xpl/mostRecentIssue.jsp?punumber=6299182>.

[4] J. C. Santana, "Predicción de series temporales con redes neuronales: una aplicación a la

inflación colombiana.," Revista Colombiana de Estadística, vol. XXIX, n. 1, pp. 77 - 92,

2006. ISSN: 0120-1751, Disponible:

<http://www.scielo.org.co/pdf/rce/v29n1/v29n1a05.pdf>.